

Performance Comparison of Super Resolution Models

* CNN, Gan, ViT hybrid 모델을 중심으로

1st Jinu Hong
HALLYM UNIVERSITY
20205276@hallym.ac.kr

Abstract—본 보고서는 CNN(Convolutional Neural Network), GAN(Generative Adversarial Network), ViT(Vision Transformer) 기반 Super-Resolution 모델의 성능을 비교·분석하여 각 접근 방식의 장단점과 작동 원리를 이해하는 것을 목표로 한다. 비교 대상으로 CNN 기반 FSRCNN, GAN 기반 ESRGAN, ViT 기반 SwinIR 및 DRCT를 선정하였으며, 사전 학습된 모델과 DF2K(DIV2K + Flickr 2K) 및 BSD100 데이터셋으로 학습한 모델을 활용하여 성능을 평가하였다. 모든 모델을 150 epoch 동안 학습한 후, Set14 데이터셋의 저해상도 이미지를 4배 확대하여 복원하고, 복원된 이미지와 정답(Ground Truth) 간의 PSNR(Peak Signal-to-Noise Ratio), SSIM(Structural Similarity Index Measure), 그리고 변환에 소요된 시간을 측정하였다. 분석 결과, CNN 및 ViT 기반 모델은 높은 PSNR 및 SSIM 점수를 기록하며 상대적으로 빠른 학습 및 추론 속도를 보였다. 반면, GAN 모델은 상대적으로 긴 학습 시간이 필요하고 PSNR 및 SSIM 점수는 낮았으나, 인간의 시각적 평가에서는 경계를 보다 뚜렷하게 복원하는 모습을 보였다. 다만, GAN 모델은 원본에 존재하지 않는 구조를 생성하는 경향이 있어, 실사용 시 신중한 고려가 필요함을 확인하였다.

I. 서론

초해상도(Super-Resolution, SR)는 저해상도(LR) 이미지를 고해상도(HR)로 변환하여 세부 정보를 복원하는 컴퓨터 비전의 핵심 과제이다. CNN, GAN, ViT 기반의 다양한 접근 방식이 제안되었으며, 각 방법은 성능, 계산 효율성, 시각적 품질 측면에서 고유한 장단점을 가진다. 본 연구에서는 각각의 접근 방식에 따라 FSRCNN, ESRGAN, SwinIR, 그리고 DRCT 모델을 비교 분석하였다. 각 모델은 사전 학습된 버전과 DF2K(DIV2K + Flickr2K), BSD100 데이터셋으로 150 epoch 동안 학습한 버전을 사용하였다. Set14 데이터셋을 활용하여 4배 Upscale 실험을 진행하고, PSNR, SSIM를 비교하여 성능을 평가하였다.

II. 평가 지표

본 연구에서는 이미지 품질 평가를 위해 PSNR(Peak Signal-to-Noise Ratio)과 SSIM(Structural Similarity Index Measure)를 사용하였다. PSNR은 신호 대 잡음 비율을 기반으로 한 수치적 평가를, SSIM은 인간의 시각적 인식을 고려한 구조적 유사성을 측정한다. 그림 1은 PSNR과 SSIM을 활용한 이미지 품질 평가 결과를 비교한 예시로, PSNR이 높더라도 시각적으로 품질 저하가 명확한 경우가 있음을 보여준다. 따라서 이미지 복원 성능을 보다 정확하게 평가하기 위해서는 PSNR과 SSIM 모두를 평가 지표로 사용하였으며, 해당 지표들의 계산 방법은 다음과 같다.



그림 1. PSNR과 SSIM을 이용한 이미지 품질 평가의 차이

A. PSNR(Peak Signal-to-Noise Ratio)

PSNR은 두 이미지 간 차이를 평균 제곱 오차(Mean Squared Error, MSE) 기반으로 측정하는 지표로, 이를 바탕으로 PSNR은 다음과 같이 계산된다.

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}^2}{\text{MSE}} \right) \quad (1)$$

여기서 MAX는 이미지의 최대 픽셀 값(예: 8비트 이미지의 경우 255)이며, PSNR 값이 클수록 두 이미지가 더 유사함을 의미한다. 그러나 PSNR은 노이즈나 블러링이 포함된 이미지에서 한계를 보인다.

B. SSIM(Structural Similarity Index Measure)

SSIM은 인간의 시각적 인식을 기반으로 이미지의 구조적 유사성을 평가하는 지표로, 단순한 픽셀 차이가 아닌 밝기(luminance), 대비(contrast), 구조(structure) 정보를 종합적으로 고려한다. SSIM은 다음과 같이 정의된다.

$$\text{SSIM}(I, K) = \frac{(2\mu_I\mu_K + C_1)(2\sigma_{IK} + C_2)}{(\mu_I^2 + \mu_K^2 + C_1)(\sigma_I^2 + \sigma_K^2 + C_2)} \quad (2)$$

μ_I, μ_K 는 각각 원본 이미지와 복원된 이미지의 평균 밝기, σ_I^2, σ_K^2 는 각각 원본 및 복원된 이미지의 분산(대비 정보), σ_{IK} 는 두 이미지 간의 공분산(구조적 유사성)을 나타내며, C_1, C_2 는 수식의 안정성을 위한 작은 상수이다.

SSIM 값은 -1에서 1 사이의 값을 가지며, 1에 가까울수록 두 이미지가 유사함을 의미한다.

III. 사용 모델

측정에 앞서, Train Data는 DIV2K와 Flickr2K를 합친 DF2K를 사용하였으며, Validation Data로는 BSD100 데이터를 사용하였다. Test Data로는 Set 14 데이터를 사용하였으며, 최종 학습된 모델과 Pretrained된 모델에 대해 각각 PSNR과 SSIM을 측정하였다.

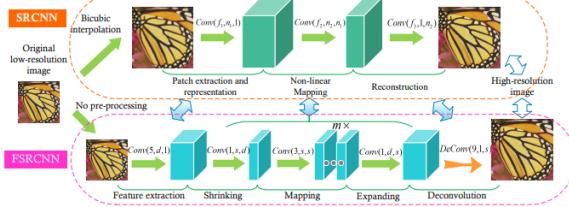


그림 2. SRCNN 과 FSRCNN의 구조

A. FSRCNN: Fast Super-Resolution CNN

FSRCNN(Fast Super-Resolution Convolutional Neural Network) [2]는 기존 SRCNN(Super-Resolution Convolutional Neural Network) [1]의 연산 효율성을 개선한 모델이다. SRCNN은 저해상도(LR) 이미지를 bicubic interpolation을 통해 선행적으로 업샘플링한 후 CNN을 적용하는 방식이었으며 [1], 이는 계산 비용이 크고 속도가 느리다는 단점이 있었다. 이를 수식으로 표현하면 다음과 같다.

$$O \{ (f_1^2 \cdot 1 \cdot n_1 + f_2^2 \cdot n_1 \cdot n_2 + f_3^2 \cdot n_2 \cdot 1) S_{HR} \} \quad (3)$$

여기서 $\{f_i\}_{i=1}^3$ 은 SRCNN의 세 Convolution Layer의 필터 크기를, $\{n_i\}_{i=1}^3$ 은 각 레이어의 필터 개수를 의미한다. S_{HR} 는 출력되는 High Resolution 이미지의 크기를 나타낸다. SRCNN의 문제점은, LR 이미지를 입력받는 것이 아니라 bicubic interpolation을 거친 후 HR 크기로 변환된 LR 이미지를 입력으로 사용해야 한다는 점이었다. 이 과정에서 연산량이 증가하고, 저해상도 이미지에서 불필요한 고주파 성분이 추가될 수 있어 모델의 학습 효율이 저하될 가능성이 있다. FSRCNN은 이러한 한계를 극복하기 위해 LR 이미지에서 직접 feature extraction을 수행한 후, 최종 단계에서 deconvolution layer를 적용하여 HR 이미지를 생성하는 방식을 사용한다. FSRCNN의 전체 구조는 다음과 같이 구성된다.

- Feature Extraction : LR 이미지에서 직접 특징을 추출하며, SRCNN보다 작은 5×5 필터를 사용하여 연산량을 줄인다. 이 단계에서 $\text{Conv}(5, d, 1)$ 연산이 수행된다.
- Shrinking: 1×1 필터를 사용하여 특정 차원을 축소한다. 즉, d 차원의 feature map을 s 차원으로 줄이는 과정이며, $\text{Conv}(1, s, d)$ 가 수행된다.
- Non-Linear Mapping: 축소된 feature map을 여러 개의 비선형 변환 레이어를 통해 고해상도 이미지 정보를 학습한다. 총 개의 3×3 컨볼루션 레이어를 통과하며, $m \times \text{Conv}(3, s, s)$ 연산이 수행된다.
- Expanding: Shrinking 단계에서 축소한 feature map을 다시 원래 차원으로 복원한다. 즉, d 차원에서 s 차원으로 확장하는 단계로, $\text{Conv}(1, d, s)$ 연산이 수행된다.
- Deconvolution: 최종적으로 deconvolution layer를 통해 초해상도 이미지를 생성한다. 즉, $\text{Conv}(9, 1, d)$ 가 수행된다.

FSRCNN의 계산 비용은 다음과 같이 표현될 수 있다.

$$O(9ms^2 + 2sd + 106d)S_{LR} \quad (4)$$

여기서 S_{LR} 은 입력되는 저해상도 이미지의 크기이며, d, s, m 은 각각 feature extraction 차원, shrinking 차원, Non-Linear Mapping의 Depth를 나타낸다.



그림 3. FSRCNN을 사용해 복원한 이미지(우측 2장)과 HR, LR 이미지

그림3은 위 내용을 참고하여 FSRCNN에서 제공한 91-Images로 학습된 Pretrained Model과 DF2K 데이터를 사용해 150 Epoch 학습시킨 모델을 통해 복원한 LR 이미지이다.

B. ESRGAN: Enhanced Super-Resolution GAN

ESRGAN (Enhanced Super-Resolution Generative Adversarial Network) [3]는 기존 SRGAN (Super-Resolution GAN) [4]을 개선하여 보다 사실적인 초해상도 이미지를 생성하는 모델이다. SRGAN은 최초로 GAN 기반 초해상도 모델을 제안하며 perceptual loss를 활용하여 고해상도 이미지를 생성하는 방식이었으나, 생성된 이미지의 품질이 완전히 자연스럽지 못하다는 한계점이 있었다. ESRGAN은 이를 해결하기 위해 SRGAN의 기본 구조를 따르면서도 Residual-in-Residual Dense Block (RRDB)을 도입하여 성능을 향상시켰다. SR 및 Deblurring과 같은 PSNR 측정 과정에서 Batch Normalization을 제거함으로써 더 좋은 성능을 낼 수 있기 때문에 [10] RRDB는 Batch Normalization을 제거하고, 더 깊은 네트워크 학습이 가능하도록 residual connection과 dense connection을 결합한 구조를 갖는다. 이를 통해 더욱 강력한 feature representation이 가능해졌다. ESRGAN의 전체 네트워크 구조는 다음과 같이 구성된다:

- Feature Extraction: 입력 저해상도(LR) 이미지에서 특징을 추출하기 위해 첫 번째 convolution layer를 적용한다.
- Residual-in-Residual Dense Block (RRDB): 여러 개의 residual dense block을 중첩하여 깊은 네트워크를 형성하고, 네트워크의 성능을 향상시킨다.
- Upsampling: Deconvolution 또는 sub-pixel convolution을 사용하여 초해상도 이미지를 생성한다.
- Discriminator: GAN 구조에서 사용되는 판별자로, 고해상도(HR) 이미지와 생성된 초해상도(SR) 이미지를 비교하여 더욱 현실적인 결과를 얻도록 학습한다.

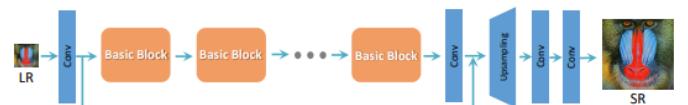


그림 4. ESRGAN의 전반적인 구조



그림 5. ESRGAN을 사용해 복원한 이미지(우측 2장)과 HR, LR 이미지

ESRGAN의 전체 구조는 다음과 같이 요약되며 그림 4과 같다. $\text{Conv}(3, 64, 1) \rightarrow \text{RRDB} \times N \rightarrow \text{Conv}(3, 64, 1) \rightarrow \text{Upsample} \times 2 \rightarrow \text{Conv}(3, 3, 1)$

또한, 기존의 SRGAN에서 사용하던 Perceptual loss를 개선하였다. 개선 사항은 다음과 같다. :

- **Relativistic Average GAN Loss:** 기존 SRGAN의 GAN loss 대신 Relativistic Average GAN Loss을 도입하여 더욱 자연스러운 초해상도 이미지를 생성할 수 있도록 하였다. 이를 통해 판별자가 실사 이미지가 가짜보다 더 진짜에 가깝다는 것을 학습하도록 유도한다.
- **Perceptual Loss:** VGG 네트워크를 기반으로 하되, feature maps의 중간 레이어를 활용하여 더욱 풍부한 고해상도 특징을 학습할 수 있도록 개선되었다.
- **Content Loss:** 픽셀 기반 MSE Loss 대신, perceptual feature space에서 비교하는 방식을 적용하여 보다 인간의 시각적 평가와 유사한 성능을 도출하였다.

ESRGAN의 계산 비용은 기존 SRGAN보다 증가하였으나, perceptual loss와 GAN loss를 통해 시각적으로 더 우수한 결과를 생성할 수 있다. 전체 연산량은 RRDB 블록 수(N)와 네트워크의 깊이에 영향을 받으며, 다음과 같이 표현될 수 있다:

$$O(N \cdot F_{RRDB} + U_{up})S_{LR}$$

여기서 F_{RRDB} 는 Residual-in-Residual Dense Block의 연산량, U_{up} 는 업샘플링 연산량, S_{LR} 은 입력 저해상도 이미지 크기를 나타낸다. 그림 5을 참고하면, ESRGAN은 기존 CNN 기반 초해상도 모델보다 높은 시각적 품질을 제공하였으며, 특히 경계가 뚜렷하고 세부 텍스처를 보다 명확하게 복원하는 성능을 보였다. 하지만 150 epoch 학습한 모델은 색감의 변화가 있는 것을 볼 수 있다.

C. SwinIR: Swin Transformer for Image Restoration

SwinIR (Swin Transformer for Image Restoration) [5]는 Swin Transformer의 계층적 윈도우 어텐션 메커니즘을 활용한 이미지 복원 모델로, CNN의 지역적 처리 능력과 Transformer의 장거리 의존성 모델링을 결합하였다. 이미지 초해상도(SR), 노이즈 제거, JPEG 압축 복원 등 다양한 저수준 비전 작업에서 SOTA 성능을 달성하며, 기존 CNN 기반 모델 대비 적은 파라미터로 높은 복원 정확도를 제공한다.

그림 6에서 볼 수 있듯이, SwinIR은 세 가지 주요 모듈로 구성된다:

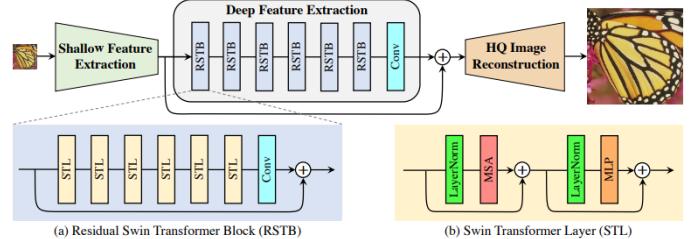


그림 6. SwinIR의 구조

- **Shallow Feature Extraction:** 입력 LR 이미지에 3×3 컨볼루션 레이어를 적용하여 저주파 특징을 추출한다.
- **Deep Feature Extraction:** K 개의 Residual Swin Transformer Block(RSTB)을 쌓아 계층적 특징을 학습한다. 각 RSTB는 Swin Transformer Layer(STL)와 Convolution Layer로 구성되며, shifted window 기법으로 Cross-Window 상호작용을 가능하게 한다. 이 과정에서 이미지의 고주파 특징을 추출한다.
- **High-resolution Reconstruction:** Sub-pixel Convolution을 사용하여 업샘플링을 수행하고, 저주파/고주파 특징을 융합하여 HQ 이미지를 생성한다.

SwinIR의 전체 구조는 다음과 같이 요약된다: $\text{Conv}(3 \times 3, C) \rightarrow [\text{RSTB} \times K] \rightarrow \text{Conv}(3 \times 3, C) \rightarrow [\text{Sub-pixel Conv}]$ 여기서 C는 특징 채널 수(기본값 180), K는 RSTB 개수(기본값 6)이다.

SwinIR에서 사용한 Loss Function은 다음과 같다:

- **L_1 pixel Loss:** 픽셀 단위 차이를 최소화하여 정밀한 복원이 가능하도록 한다. I_{RHQ} 는 I_{LQ} 로부터 얻어진 HQ 이미지이다.

$$\mathcal{L} = \|I_{RHQ} - I_{HQ}\|_1 \quad (5)$$

- Charbonnier loss : VGG 네트워크의 feature maps을 기반으로 시각적 품질을 향상시킨다.

$$\mathcal{L} = \sqrt{\|I_{RHQ} - I_{HQ}\|^2 + \epsilon^2} \quad (6)$$



그림 7. SwinIR을 사용해 복원한 이미지(우측 2장)과 HR, LR 이미지

D. DRCT :Deep Residual Channel Transformer

DRCT (Deep Residual Channel Transformer) [6]는 Residual Learning과 Channel-wise Transformer를 결합한 이미지 초해상도 모델로, 고해상도 이미지 복원 시 중요한 정보를 더욱

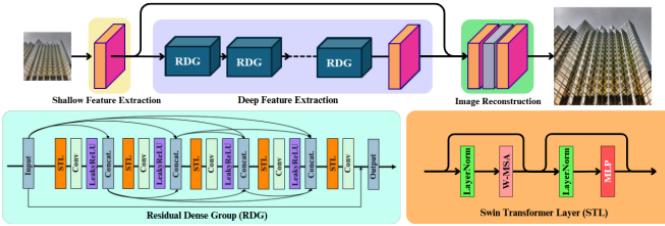


그림 8. DRCT의 구조

효과적으로 학습할 수 있도록 설계되었다. DRCT는 채널 간 관계를 강화하여 보다 정밀한 이미지 복원이 가능하도록 하며, 특히 복잡한 텍스처를 포함한 이미지에서도 우수한 성능을 보인다.

DRCT는 Residual Learning과 Channel Transformer 블록을 조합하여, 중요한 채널 정보를 강조하면서도 깊은 특징을 효과적으로 학습하는 구조를 갖는다. 주요 네트워크 구성 요소는 다음과 같다:

- Shallow Feature Extraction:** 초기 특징을 추출하기 위한 convolution layer이다.
- Deep Feature Extraction:** 여러 개의 Residual Dense Group(RDG) 내에 다수의 Swin-Dense-Residual-Connected Block(SDRCB)을 배치하여, 각 블록 내에서 dense-residual 연결을 통해 깊은 특징을 효과적으로 학습하고 정보 손실(정보 복원 현상)을 완화한다.
- Reconstruction:** 추출된 저주파/고주파 특징을 결합하여 업샘플링 과정을 거치며 고해상도 이미지를 생성한다.

DRCT의 손실 함수는 Same-task progressive training 전략 (SPTS)을 채택하여 ImageNet에서 Pretrained 된 모델을 \mathcal{L}_1 loss를 통해 조정, 이후 마지막으로 \mathcal{L}_2 loss를 사용하여 단일 픽셀과 boundary artifacts를 제거한다. 즉, 고주파 특성을 먼저 학습한 후, 저주파 학습에 맞게 한 번 학습을 진행함으로서, 세부 사항을 잘 구현하면서 자연스러운 이미지를 복원할 수 있다.

실험 결과, DRCT는 세부 텍스처를 보다 정교하게 복원할 수 있으며, FSRCNN을 제외한 두 모델에서 관측할 수 있던 boundary artifacts가 눈에 띠게 감소한 것을 확인할 수 있었다.

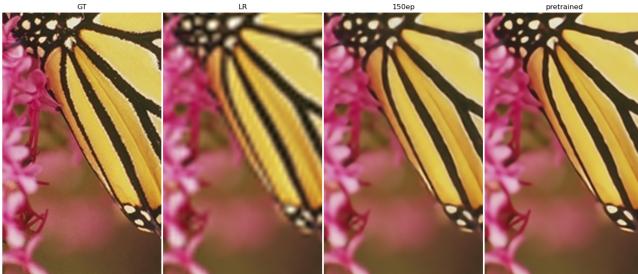


그림 9. DRCT를 사용해 복원한 이미지(우측 2장)과 HR, LR 이미지

IV. 결론

다음 표에는 각 모델의 PSNR 점수와 SSIM 점수를 비교한 표이다.

Model Name	PSNR	SSIM
FSRCNN Pretrained	27.27	0.77
FSRCNN DF2K 100 epoch	27.3	0.78
ESRGAN Pretrained	25.33	0.71
ESRGAN DF2K 150 epoch	25.79	0.71
SwinIR Pretrained	28.86	0.81
SwinIR DF2K 150 epoch	27.73	0.77
SwinIR DF2K 700 epoch	27.88	0.78
DRCT Pretrained	28.99	0.81
DRCT DF2K 120 epoch	27.99	0.79

해당 결과와, 복원된 이미지를 고려하여 종합한다면, FSRCNN은 경량화된 네트워크 구조와 효율적인 연산 덕분에 빠른 속도를 제공하며, PSNR과 SSIM과 같은 객관적 평가 지표에서도 우수한 성능을 보인다. 그러나 단순한 모델 구조로 인해 복잡한 텍스처나 고주파 세부 정보를 정밀하게 복원하는데 한계가 있다. 즉, 실시간 응용에서는 유리하나, 세밀한 디테일 복원이 중요한 경우에는 부족할 수 있다는 점이 주요 단점으로 작용할 수 있다. 하지만 학습 시간 측면에서 본다면 가장 적은 자원을 통해 빠르게 학습이 가능하다는 장점이 존재한다.

ESRGAN의 PSNR과 SSIM 점수는 다른 모델보다 낮은 경향을 보이는데, 이는 GAN 기반 모델이 픽셀 단위 오차 최소화보다는 사람의 주관적 평가에 더 최적화되었기 때문이다. 실제로, GAN 기반 초해상도 모델은 고주파 성분을 강조하면서 원본 데이터에 존재하지 않는 패턴을 추가할 가능성이 있어, 일부 애플리케이션에서는 주의가 필요하다. 특히 의료 영상, 위조 방지 시스템과 같은 정밀한 복원이 필요한 영역에서는 GAN 모델의 사용을 신중히 고려해야 한다. 또한, ESRGAN이 생성한 초해상도 이미지의 품질은 주관적인 시각적 평가에서는 우수하지만, PSNR 및 SSIM과 같은 전통적인 수치 기반 지표에서는 다소 불리할 수 있음을 감안해야 한다. 이는 perceptual loss와 GAN loss가 픽셀 기반 손실보다 인간의 인지적 품질 향상에 초점을 맞추기 때문으로 분석된다.

SwinIR은 Swin Transformer를 기반으로 하여, 윈도우 단위의 self-attention과 계층적 특징 추출을 통해 지역적 및 전역적 정보를 효과적으로 학습한다. 그 결과, 높은 PSNR과 SSIM 점수뿐만 아니라 우수한 시각적 품질도 확보할 수 있었다. 다만, Transformer 기반의 복잡한 구조로 인해 연산량이 증가하고, 실시간 처리에는 상대적으로 어려움이 있을 수 있다. 또한, 일부 상황에서는 미세한 텍스처 복원에서 불안정한 결과가 나타날 가능성도 존재한다.

DRCT는 Residual Learning과 Channel-wise Transformer를 결합하여 채널 간 관계를 강화함으로써, 복잡한 텍스처와 색상 정보를 정밀하게 복원하는 데 강점을 보인다. DRCT는 객관적 평가 지표에서도 우수한 성능을 나타내지만, 채널 간 상호작용에 따른 부수 효과로 인해 경우에 따라 노이즈가 증가하거나 원본에 존재하지 않는 패턴이 생성될 가능성이 있다. 이러한 현상은 모델의 복잡한 채널 관계 학습 과정에서 발생할 수 있는 한계로 해석되나, SwinIR에 비해 더 적은 학습 시간과 시각적으로 자연스러운 복원 결과를 얻을 수 있다.

REFERENCES

- [1] Chao Dong, Chen Change Loy, Kaiming He, Xiaoou Tang, “Image Super-Resolution Using Deep Convolutional Networks” , Fri, 31 Jul 2015.
- [2] Chao Dong, Chen Change Loy, Xiaoou Tang, “Accelerating the Super-Resolution Convolutional Neural Network” , Mon, 1 Aug 2016.
- [3] Xintao Wang, Ke Yu, Shixiang Wu, Jinjin Gu, Yihao Liu, Chao Dong, Chen Change Loy, Yu Qiao, Xiaoou Tang , “ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks” , Mon, 17 Sep 2018
- [4] . Ledig, C., Theis, L., Husz’ar, F., Caballero, J., Cunningham, A., Acosta, A., Aitken, A., Tejani, A., Totz, J., Wang, Z., “Photo-realistic single image superresolution using a generative adversarial network. ”, CVPR, 2017
- [5] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, Yoshua Bengio, “Generative Adversarial Networks” , Tue, 10 Jun 2014
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin , “Attention Is All You Need” , Wed, 2 Aug 2023
- [7] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, Baining Guo , “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows” , Tue, 17 Aug 2021
- [8] Jingyun Liang, Jiezheng Cao, Guolei Sun, Kai Zhang, Luc Van Gool, Radu Timofte , “SwinIR: Image Restoration Using Swin Transformer” , Mon, 23 Aug 2021
- [9] Chih-Chung Hsu, Chia-Ming Lee, Yi-Shiuan Chou , “DRCT: Saving Image Super-resolution away from Information Bottleneck” , Sat, 23 Nov 2024
- [10] Lim, B., Son, S., Kim, H., Nah, S., Lee, K.M.: Enhanced deep residual networks for single image super-resolution. In: CVPRW. (2017)



그림 10. 모델별 고주파 특성의 복원 비교

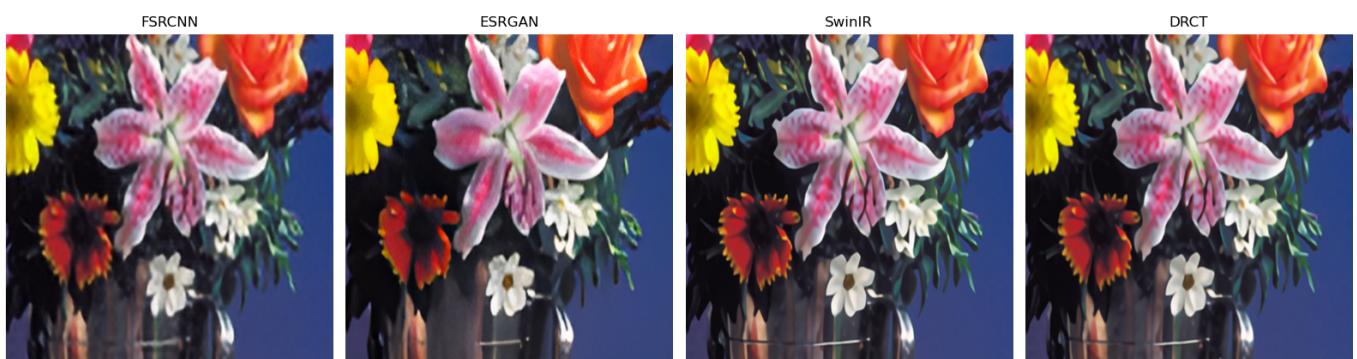


그림 11. GAN 모델의 패턴 이미지 패턴 소실



그림 12. DRCT의 낮은 Artifact Boundary